

# **TRACCIAMENTO DELLE TECNOLOGIE EMERGENTI CON NEO4J E BERT UTILIZZANDO I DATI DI ARXIV**

EMANUELE DI LUZIO

UNIVERSITÀ DEGLI STUDI DI MODENA E REGGIO EMILIA

# ABSTRACT

Questa presentazione esplora l'uso dei Knowledge Graph dinamici per tracciare l'evoluzione delle tecnologie emergenti. Utilizzando Neo4j come database a grafo e l'API di arXiv per accedere ai dati dei paper scientifici, la ricerca mira a identificare trend tecnologici e collaborazioni tra ricercatori. L'integrazione iniziale con BabelNet è stata sostituita da WordNet e successivamente con BERT per migliorare la similarità semantica tra i documenti.

# INTRODUZIONE

IMPORTANZA DELLA TRACCIABILITÀ DELLE TECNOLOGIE EMERGENTI  
KNOWLEDGE GRAPH (KG) PER RAPPRESENTARE RELAZIONI COMPLESSE

OBIETTIVI:

1

RACCOLTA DATI TRAMITE API DI ARXIV

2

CREAZIONE DI UN KG DINAMICO CON NEO4J

3

ANALISI DELLE TECNOLOGIE EMERGENTI E COLLABORAZIONI

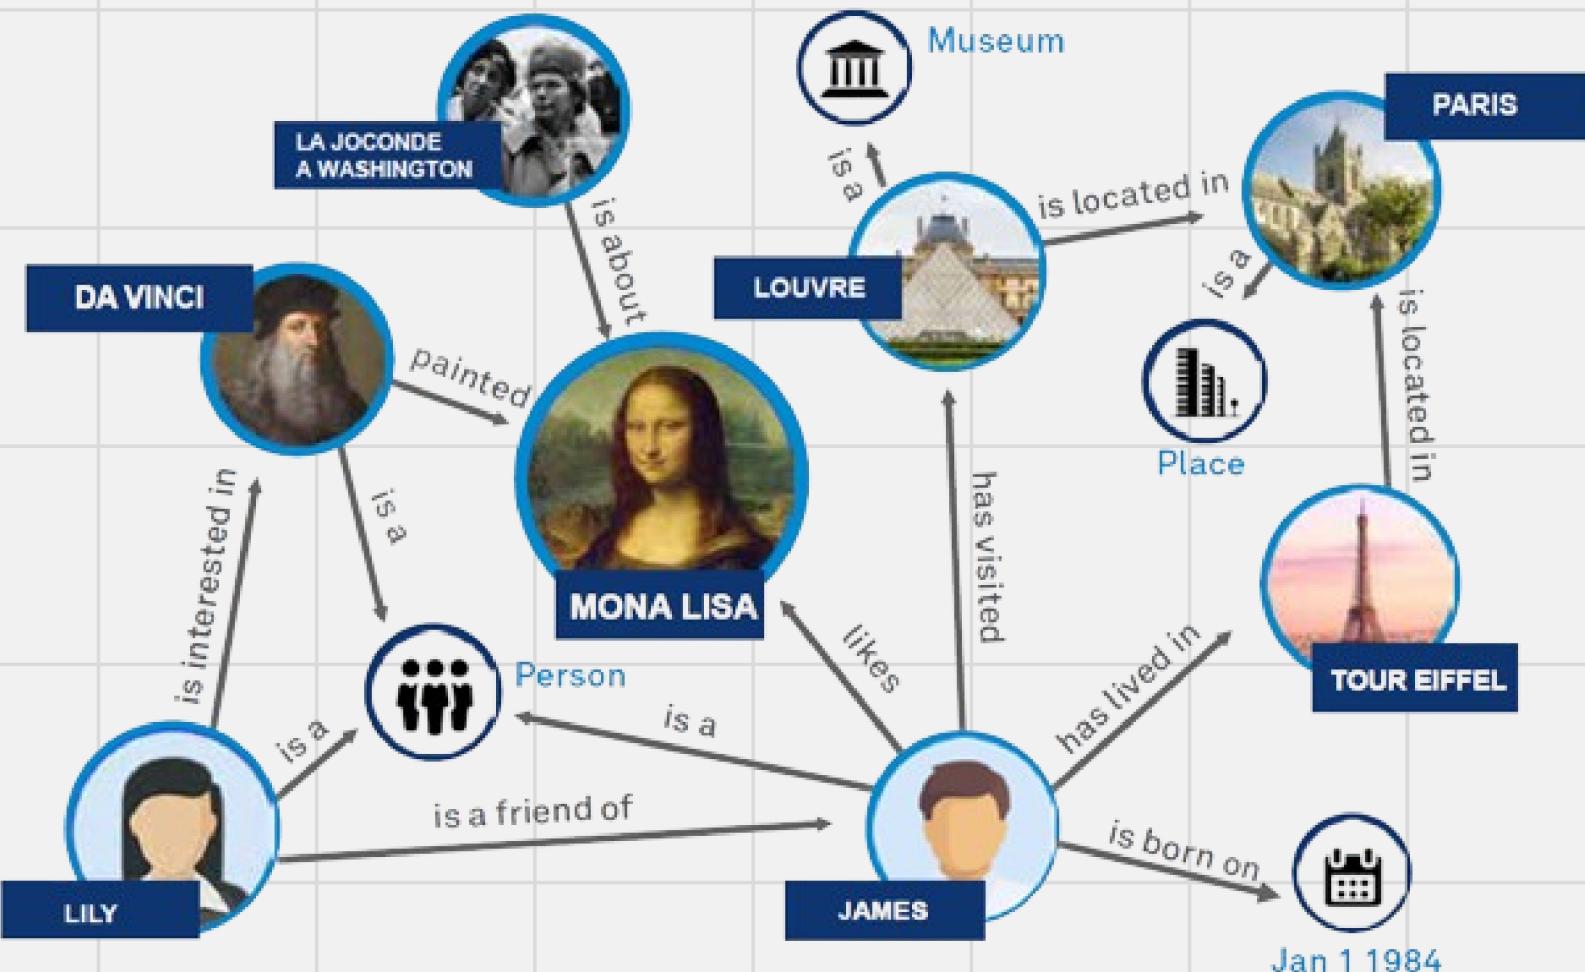
4

BREVE MENZIONE DELLE SFIDE INCONTRATE CON BABELNET E WORDNET PER  
POI PASSARE A BERT.

5

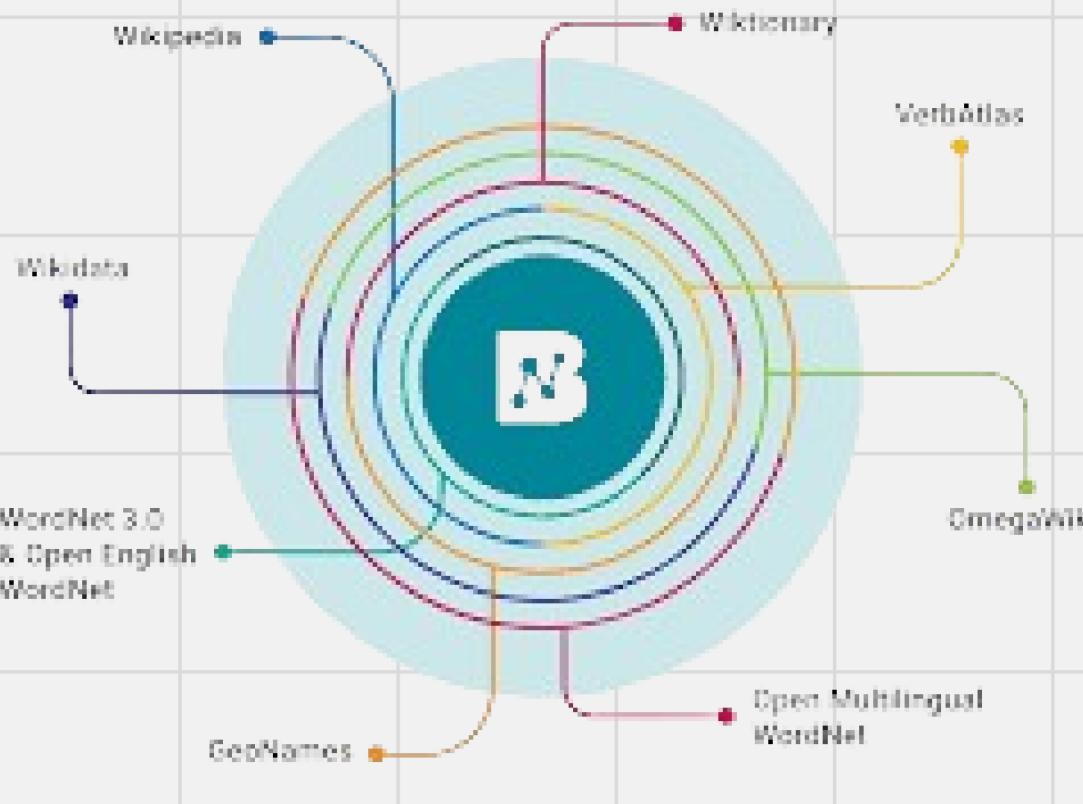
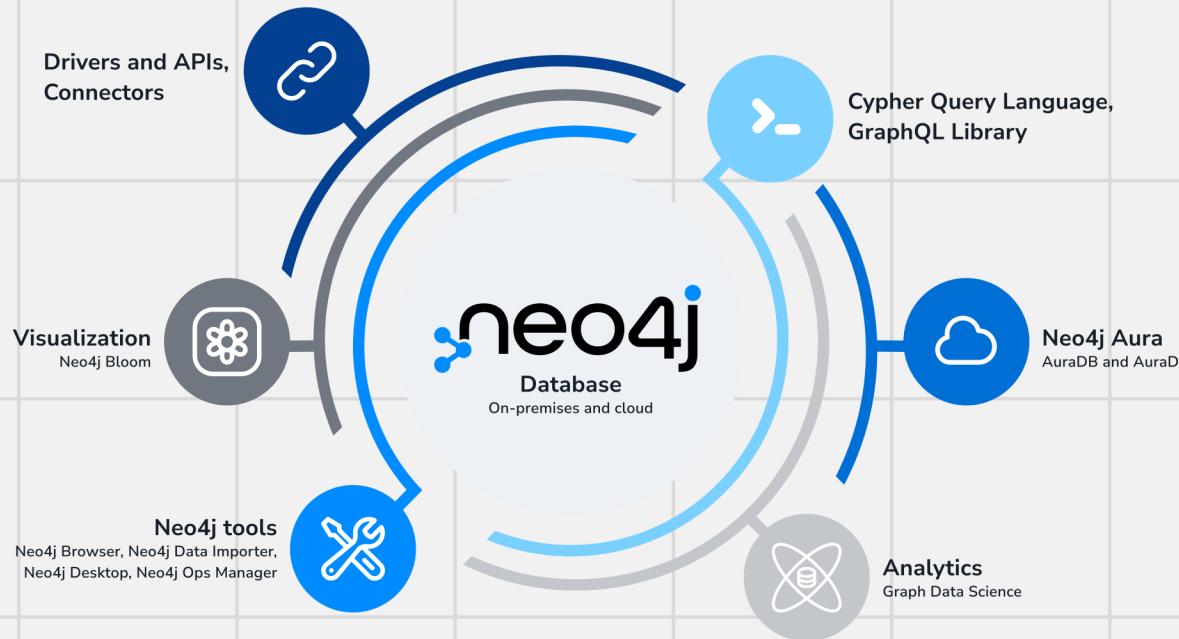
CONCLUSIONI

# KNOWLEDGE GRAPH E UTILIZZI



- MODELLAZIONE DELLE ENTITÀ E RELAZIONI: RAPPRESENTAZIONE STRUTTURATA DELLA CONOSCENZA.
- APPLICAZIONI PRINCIPALI:
  - A. MOTORI DI RICERCA: GOOGLE UTILIZZA KG PER MIGLIORARE LA RILEVANZA DEI RISULTATI.
  - B. SISTEMI DI RACCOMANDAZIONE: NETFLIX E AMAZON SUGGERISCONO CONTENUTI BASATI SULLE PREFERENZE.
  - C. ANALISI DEI DATI AZIENDALI: TRACCIAMENTO E OTTIMIZZAZIONE DELLE CATENE DI APPROVVIGIONAMENTO.

# STRUMENTI E TECNICHE UTILIZZATE



- Neo4j: Database a grafo nativo.
- NLP: Analisi di informazioni testuali.
- BERT: Utilizzato per migliorare la correlazione semantica dopo la valutazione dei limiti di BabelNet e WordNet.

# IMPLEMENTAZIONE CON NEO4J

Download e Preparazione dei Dati di arXiv: Utilizzo di Python per scaricare e preparare i dati.

```
IMPORT REQUESTS
IMPORT XML.ETREE.ELEMENTTREE AS ET
IMPORT CSV

DEF FETCH_ARXIV_DATA(QUERY, MAX_RESULTS=100):
    BASE_URL = "HTTP://EXPORT.ARXIV.ORG/API/QUERY?"
    SEARCH_QUERY = F"SEARCH_QUERY={QUERY}&START=0&MAX_RESULTS={MAX_RESULTS}"
    RESPONSE = REQUESTS.GET(BASE_URL + SEARCH_QUERY)
    RETURN RESPONSE.TEXT

DATA = FETCH_ARXIV_DATA("ALL:DEEP LEARNING")
ROOT = ET.FROMSTRING(DATA)
ENTRIES = ROOT.FINDALL('{HTTP://WWW.W3.ORG/2005/ATOM}ENTRY')

WITH OPEN("ARXIV_DATA.CSV", "W") AS FILE:
    WRITER = CSV.WRITER(FILE)
    WRITER.WRITEROW(["ID", "TITLE", "AUTHORS", "CATEGORIES", "ABSTRACT", "CREATED", "UPDATED"])
    FOR ENTRY IN ENTRIES:
        ID = ENTRY.FIND('{HTTP://WWW.W3.ORG/2005/ATOM}ID').TEXT
        TITLE = ENTRY.FIND('{HTTP://WWW.W3.ORG/2005/ATOM}TITLE').TEXT
        AUTHORS = [AUTHOR.FIND('{HTTP://WWW.W3.ORG/2005/ATOM}NAME').TEXT FOR AUTHOR IN ENTRY.FINDALL('{HTTP://WWW.W3.ORG/2005/ATOM}AUTHOR')]
        CATEGORIES = [CATEGORY.ATTRIB['TERM'] FOR CATEGORY IN ENTRY.FINDALL('{HTTP://ARXIV.ORG/SCHEMAS/ATOM}CATEGORY')]
        ABSTRACT = ENTRY.FIND('{HTTP://WWW.W3.ORG/2005/ATOM}SUMMARY').TEXT
        CREATED = ENTRY.FIND('{HTTP://WWW.W3.ORG/2005/ATOM}PUBLISHED').TEXT
        UPDATED = ENTRY.FIND('{HTTP://WWW.W3.ORG/2005/ATOM}UPDATED').TEXT
        WRITER.WRITEROW([ID, TITLE, ','.JOIN(AUTHORS), ','.JOIN(CATEGORIES), ABSTRACT, CREATED, UPDATED])
```

QUESTO SCRIPT PYTHON SCARICA I DATI DA ARXIV UTILIZZANDO LA LORO API, ESTRAE INFORMAZIONI RILEVANTI COME ID, TITOLO, AUTORI, CATEGORIE, ABSTRACT, DATA DI CREAZIONE E AGGIORNAMENTO, E LI SALVA IN UN FILE CSV PER UN ULTERIORE UTILIZZO.

# IMPORTAZIONE DEI DATI NEL GRAFO

Script Cypher: Per importare i dati in Neo4j.



```
LOAD CSV WITH HEADERS FROM 'FILE:///PATH/TO/ARXIV_DATA.CSV' AS ROW
MERGE (P:PAPER {ID: ROW.ID, TITLE: ROW.TITLE, ABSTRACT: ROW.ABSTRACT, CREATED: ROW.CREATED,
UPDATED: ROW.UPDATED})
UNWIND SPLIT(ROW.AUTHORS, ",") AS AUTHOR
MERGE (A:AUTHOR {NAME: TRIM(AUTHOR)})
MERGE (P)-[:AUTHORED_BY]->(A)
UNWIND SPLIT(ROW.CATEGORIES, ",") AS CATEGORY
MERGE (C:CATEGORY {NAME: TRIM(CATEGORY)})
MERGE (P)-[:BELONGS_TO]->(C)
```

QUESTO SCRIPT CYpher CARICA I DATI DAL FILE CSV IN NEO4J. CREA NODI PER I PAPER, AUTORI E CATEGORIE, E DEFINISCE LE RELAZIONI TRA LORO, COME "AUTHORED\_BY" PER INDICARE CHI HA SCRITTO IL PAPER E "BELONGS\_TO" PER INDICARE LA CATEGORIA DEL PAPER.

# IINTEGRAZIONE CON BABELNET E WORDNET E PASSAGGIO A BERT

## **Problemi con BabelNet:**

- Confronto di singoli synset, riduzione della complessità semantica.
- Similarità binarie (1 o 0), poche gradazioni intermedie.
- Difficoltà nel formare gruppi significativi di pareri.
- Analisi limitata ai titoli, ignorando abstract e contenuti.
- Richiesta di sforzo computazionale e logistico elevato.

## **Transizione a WordNet:**

- Creazione di cluster di parole per i titoli.
- Implementazione di metriche di similarità (path, Wu-Palmer).
- Calcolo della media delle similarità tra synset.
- Considerazione solo delle similarità superiori a 0.6.

## **Passaggio a BERT:**

- Generazione di rappresentazioni dinamiche delle parole.
- Migliore cattura delle sfumature e del contesto.
- Risultati più accurati rispetto a WordNet e BabelNet.
- Uso della libreria Transformers per tokenizzazione e embedding.

# **IMPORTAZIONE DELLE SIMILARITÀ NEL GRAFO**

- Importazione delle relazioni di similarità calcolate nel grafo Neo4j.
- Utilizzo delle relazioni per analisi e visualizzazioni ulteriori.

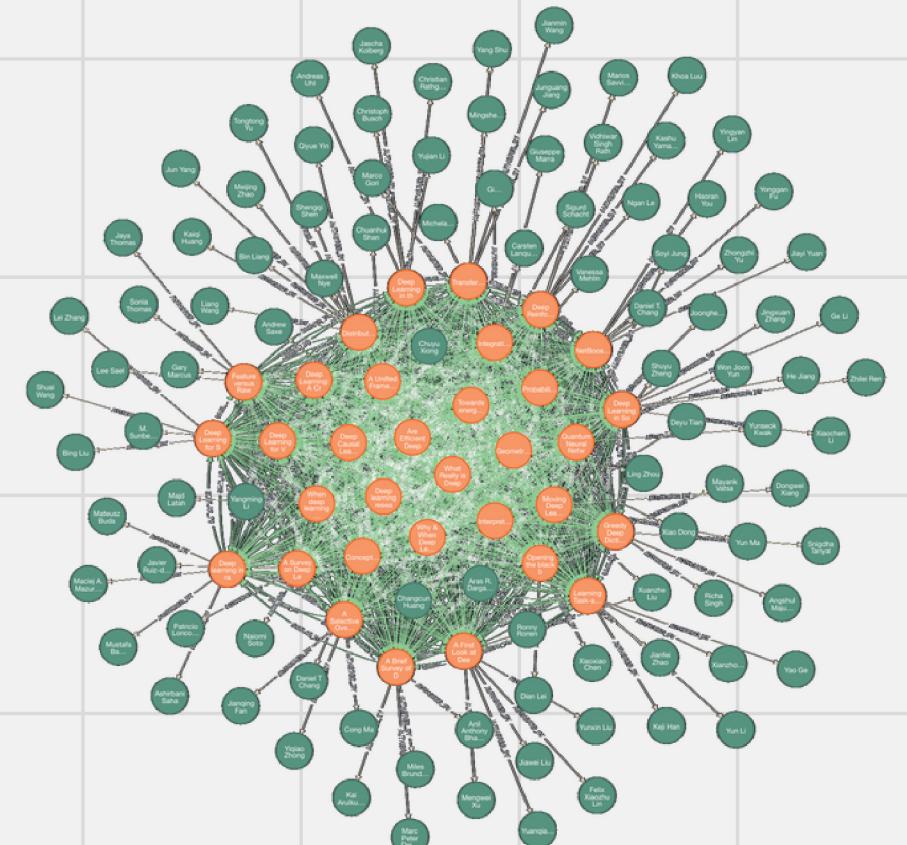
**Script Cypher: Per integrare i concetti di BERT nel grafo.**

```
// Caricamento delle relazioni di similarità
LOAD CSV WITH HEADERS FROM 'file:///similarity_edges.csv' AS row

// Creazione delle relazioni di similarità tra i paper
MATCH (p1:Paper {id: row.Paper1})
MATCH (p2:Paper {id: row.Paper2})
MERGE (p1)-[:SIMILAR_TO {similarity: toFloat(row.Similarity)}]->(p2);
```

# ANALISI E VISUALIZZAZIONE

- Collaborazioni tra Autori: Visualizzazione delle reti di collaborazione.
- Confronto delle Tecnologie per Anno



Questa query Cypher trova le collaborazioni tra autori e restituisce una lista di coautori per ogni autore.

```
MATCH (a:Author)-[:AUTHORED_BY]->(p:Paper)<-
[:AUTHORED_BY]-(coauthor:Author)
RETURN a.name AS Author,
collect(coauthor.name) AS CoAuthors
```

Questa query Cypher identifica le tecnologie rilevanti in base al numero di paper pubblicati in ciascuna categoria per anno, ordinando i risultati per anno e numero di paper.

```
MATCH (p:Paper)-[:BELONGS_TO]->(c:Category)
RETURN c.name AS Category, p.created AS Year,
count(p) AS PaperCount
ORDER BY Year, PaperCount DESC
```

# CONCLUSIONI

Importanza dei dati dinamici nei KG: Essenziale per tracciare l'evoluzione delle tecnologie emergenti e comprendere le direzioni future della ricerca scientifica. Utilizzo di Neo4j, WordNet e BERT: Neo4j ha permesso la creazione di un Knowledge Graph dinamico dettagliato. WordNet ha migliorato la correlazione semantica, ma l'integrazione di BERT ha superato molte limitazioni precedenti, fornendo una comprensione più profonda e accurata delle correlazioni semantiche tra i paper. Future Work: Ampliamento dell'analisi per includere ulteriori fonti di dati e l'applicazione di algoritmi di machine learning più avanzati per migliorare le previsioni sulle tendenze tecnologiche. L'integrazione di risorse multilingue e tecniche avanzate di NLP potrebbe migliorare ulteriormente la qualità delle analisi e delle previsioni.

## Bibliografia

- Neo4j Documentation. (2023). Retrieved from <https://neo4j.com/docs/>
- arXiv API Documentation. (2023). Retrieved from <https://arxiv.org/help/api/user-manual>
- "Synthesis of multilevel knowledge graphs: Methods and technologies for dynamic networks" by Man T., Vodyaho A., Ignatov D.I., Kulikov I., Zhukova N. (2023). Engineering Applications of Artificial Intelligence, 123, art. no. 106244.
- Navigli, R., & Ponzetto, S. P. (2012). BabelNet: The automatic construction, evaluation and application of a wide-coverage multilingual semantic network. Artificial Intelligence, 193, 217-250.
- Fellbaum, C. (1998). WordNet: An Electronic Lexical Database. MIT Press.
- Miller, G. A. (1995). WordNet: A Lexical Database for English. Communications of the ACM, 38(11), 39-41.
- Scikit-Learn Documentation. (2023). Retrieved from <https://scikit-learn.org/stable/documentation.html>
- Devlin, J., Chang, M. W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. In Proceedings of NAACL-HLT (pp. 4171-4186).